



# UNIVERSITÀ DEGLI STUDI DI SALERNO



## Progetto di Intelligenza Artificiale

Studente	Matricola
Scaparra Daniele Pio	0512116260
Fasolino Pietro	0512116473
Vitulano Antonio	0512116776

**Link alla repository GitHub:**

<https://github.com/dscap02/EmotionsRelease>

# Documento di Data Preparation

## Indice

1	Introduzione	3
2	Obiettivi comuni	3
3	Metodo1	4
4	Metodo 2	5
5	Valutazione del metodo 1 e del metodo 2	6
6	Accorpamento delle emozioni ed eliminazioni di quelle ambigue	7
7	Bilanciamento	8
8	Differenza tra dataset iniziale e bilanciato	8

# 1 Introduzione

Lo step da realizzare in questa fase è quello relativo al **feature engineering**, cioè andando a selezionare caratteristiche più rilevanti, processo molto importante, per la risoluzione del problema. Include inoltre anche la pulizia dei dati in base ai problemi rilevati sulla qualità dei dati nella fase precedente, sulla base della pulizia dei dati, stimiamo quanto le caratteristiche sono rilevanti per la risoluzione del problema. Alla fine i dati vengono formattati per poter essere utilizzati come input nel modello, in base ai tool definiti nella fase di business understanding.

## 2 Obiettivi comuni

Nella fase precedente, di Data Understanding, è stata fatta un'analisi approfondita dei dati, che ha evidenziato dalle 27 emozioni, alcune istanze che presentavano una correlazione di due o più emozioni, in merito a ciò è stata fatta un'ulteriore analisi, che ha prodotto per ogni emozione quali erano le istanze che presentavano correlazioni con un'altra emozione, così da poter utilizzare tale prodotto come input o anche guida su cui basarsi, per effettuare operazioni di pulizia e accorpamento sul dataset. Inoltre sono stati individuati degli obiettivi comuni, di seguito verranno illustrati.

- **eliminazione dei valori null**, si noti che dato che il nostro dataset è "particolare", non ci sono mai stati valori null.
- **accorpamento delle emozioni simili**, dato che il nostro dataset ha un totale di 27 emozioni, abbiamo deciso di accorparle, sostanzialmente per due motivi. Il primo è che per fare un report tutte queste emozioni sembrano inutili e molto difficile da gestire, il secondo è che molte emozioni, ci sono sembrate molto simili tra di loro
- **eliminazione delle emozioni ambigue** nel dataset abbiamo rilevato delle emozioni che secondo noi sono molto difficile da interpretare, potrebbero essere sia in un contesto positivo che in un contesto negativo, quindi a scanso di equivoci abbiamo deciso di eliminarle proprio.

due parole vanno spese sulla gestione delle correlazioni, come accennate più volte in precedenza. Per rendere il modello più "bravo" a interpretare l'emozione e per rendere meno faticosa, la successiva fase di Data Balancing, abbiamo deciso che ad ogni messaggio verrà associata una e un'unica emozione, Ma per evitare di perdere informazioni, non le volevamo semplicemente eliminare, quindi dopo un'attenta analisi abbiamo deciso che nel caso in cui sono messaggi che hanno più di un'emozione associata, verrà associato ad esso l'emozione più indicativa, ad esempio; mess1 con emozione 0,20,15 e l'emozione più indicativa è emozione 0, l'istanza diventerà mess1 con emozione 0. Ma questa operazione diventa molto costosa, quindi per farla abbiamo individuato due metodi, ognuno fatto e portato avanti da due membri diversi del gruppo, e successivamente scelto il migliore e quello che ci sembrava più efficiente. Prima di esporre i due metodi, bisogna premettere che noi abbiamo fatto la scelta di eliminare tutte le istanze che contenevano una correlazione con l'emozione neutra, perchè ci sembrava concettualmente sbagliato.

### 3 Metodo1

Il metodo per levare le correlazioni è stato quello di usare un altro modello di intelligenza artificiale, questo metodo si divide in due fasi. fase 1 (Testing dell'intelligenza artificiale) Generare un documento di testo con alcuni testi con delle emozioni correlate, dallo in input all'intelligenza artificiale chiedendoli quale emozione è predominante, successivamente andare a controllare le risposte e vedere quale secondo il modello era l'emozione predominante, controllando se noi del gruppo eravamo d'accordo o no. Per evitare di fare errori è dato che nel gruppo non risiede una persona con competenze in psicologia, abbiamo deciso che in questa fase tutti e tre i membri del gruppo leggevano la risposta e poi ognuno dava la propria opinione. Dopo questa fase di "testing" si è deciso di usare chatgpt per la pulizia. fase 2(Prompt) La fase 2 consiste nel dare in input il dataset a chat gpt e con un prompt farsi generare il dataset senza correlazione, di seguito verrà mostrato il prompt utilizzato

ciao sto facendo un progetto di intelligenza artificiale, e in questo momento ci stiamo concentrando sulla fase di pulizia del dataset.

Io ho un dataset con due colonne:

1. La prima rappresenta il messaggio.
2. La seconda rappresenta l'emozione.

Ora ci sono alcuni messaggi che hanno l'emozione correlata.

Ad esempio, messaggio 1 ha 0,20. Tu queste istanze le devi modificare e renderle con una sola emozione, quella predominante.

Esempio: se abbiamo mess 0,9 e l'emozione predominante è 9, la riga diventa mess1 emozione 9.

Per ulteriore chiarezza, ogni emozione è associata a un numero che segue:

0 ammirazione

1 divertimento

2 rabbia

3 fastidio

4 approvazione

5 premura

6 confusione

7 curiosità

8 desiderio

9 delusione

10 disapprovazione

11 disgusto

12 imbarazzo

13 entusiasmo

14 paura

15 gratitudine

16 dolore

17 gioia

18 amore

19 nervosismo

20 ottimismo

21 orgoglio

22 consapevolezza

23 sollievo

24 rimorso

25 tristezza

26 sorpresa

27 neutra

## 4 Metodo 2

Un possibile metodo alternativo ideato per poter effettuare l'accorpamento, di istanze che presentano una correlazione di più emozioni, in un'unica emozione, tale idea si basa su una caratteristica del testo, che è la parola chiave.

Come step iniziale, l'individuazione di possibili parole chiavi (tra cui verbi e sostantivi), legati alle due emozioni correlate, prendendo ad esempio in considerazione l'emozione

"Divertimento" e l'emozione "Premura". Su queste due emozioni sono stati definiti due vocabolari, contenenti delle parole chiavi, associate ad un indice, con anche l'aiuto del modello gpt, per avere dei set più completi e ordinati. Successivo step è stato utilizzare una funzione, per ottenere dal dataset filtrato un dataframe contenente solo le istanze relative all'emozione "Divertimento" (stesso procedimento anche per l'altra emozione), tale funzione ottiene il contenuto della colonna relativa alla target, effettua la conversione in una lista di interi, e controlla se in questa lista è presente il numero dell'emozione (nel nostro caso 1), specificato nei parametri. Dopo aver ottenuto tutte le istanze relative a divertimento e l'altra emozione, l'idea è quella di calcolare la frequenza delle parole chiavi ottenute, all'interno di queste istanze. Con l'utilizzo della libreria **TextBlob**, abbiamo esaminato ogni parola per ogni testo di ogni istanza, dopo averlo convertito in stringa (se necessario) e in formato minuscolo, estraiamo le singole parole, e le confrontiamo con il vocabolario ottenuto, così da incrementare la frequenza di una determinata parola chiave.

Al termine della funzione le parole chiavi più frequenti, vengono ordinate in ordine decrescente in base alla frequenza, così poi da ottenere come risultato finale un nuovo set contenente le parole chiavi più frequenti, selezionando quelle a partire da una frequenza medio alta, e significative, relate a quell'emozione (stesso procedimento per entrambe le emozioni, in questo caso però per la seconda emozione "premura", abbiamo ricavato le sue parole chiavi dalle poche istanze che davano una correlazione in output), che possono influire maggiormente sulla correlazione.

Arriviamo così alla descrizione della funzione principale utilizzata per ricavare dalle istanze con correlazione di più emozioni, quella predominante, però innanzitutto abbiamo ottenuto, mediante funzione, ottenendo così un nuovo dataframe, con tutte quelle istanze che presentavano tale correlazione (divertimento, premura). Questa funzione (**classify emotion with sentiment**), utilizza sempre la libreria TextBlob, per esaminare le singole parole del testo di un messaggio, utilizza appunto i due set di parole chiavi delle due emozioni ottenuti precedentemente. Si ottengono le parole di un messaggio, e si salvano in una variabile temporanea, scorriamo questa variabile temporanea, per confrontare le parole sia con il set di parole chiavi di divertimento che con quelle di premura, andando a conteggiarle e salvare tutto in due variabili di conteggio. Inoltre con la libreria definita precedentemente, permette di poter analizzare anche il tono e l'attitudine della frase, così da poter influire e rendere l'output finale ancora più attendibile. Si effettua il confronto finale tra le variabili di conteggio di "**divertimento**" e "**premura**", per vedere quale delle due prevale, se c'è parità nel numero di parole chiavi delle emozioni, entra in gioco la valutazione del tono, che riporta il valore che è la polarità, se è maggiore di zero allora l'emozione è divertimento, altrimenti l'emozione è premura. Infine viene salvato il risultato della funzione applicata sul dataframe, in modo più specifico sulla colonna (0) contenente i testi dei messaggi.

## 5 Valutazione del metodo 1 e del metodo 2

Si è deciso di usare il metodo 1 perchè abbiamo notato che di base è più veloce e anche efficiente, però la tecnica descritta nel secondo metodo, sicuramente ha bisogno di essere testata maggiormente sugli input, però da alcuni risultati ottenuti, confrontandola con il modello gpt, riportano che gli output di questo metodo, cioè l'emozione predominante ricavata, coincidono con quelli del modello pre addestrato gpt. Quindi effettuando gli opportuni ulteriori casi di test successivi a quelli già ottenuti, che hanno già rilevato un

piccolo grado di efficienza, potrebbe essere usato in altre applicazioni legate al contesto.

## 6 Accorpamento delle emozioni ed eliminazioni di quelle ambigue

Come accennato in precedenza si è deciso di accorpare le emozioni che sembravano simili e di eliminare quelle ambigue. Le emozioni che abbiamo levato sono sorpresa e curiosità. di seguito verra mostrata una tabbella che indica l'emozione che è stata inglobata e in qual è l'emozione inglobante con il relativo motivo

<b>emozione</b>	<b>Emozione che ingloba</b>	<b>motivo</b>
18 (amore)	0 (ammirazione)	L'amore implica l'ammirazione
16 (dolore)	25 (tristezza)	Il dolore è una forma intensa di tristezza
9 (delusione)	25 (tristezza)	La delusione porta spesso alla tristezza
15 (gratitudine)	4 (approvazione)	La gratitudine nasce dall'approvazione di un'azione
3 (fastidio)	2 (rabbia)	Se sei infastidito sei anche arrabbiato
22 (consapevolezza)	7 (curiosità)	La consapevolezza deriva dalla curiosità
8 (desiderio)	0 (ammirazione)	Se desideri qualcosa dovresti ammirarla
12 (imbarazzo)	25 (tristezza)	L'imbarazzo spesso provoca la tristezza
19 (nervosismo)	2 (rabbia)	Il nervosismo implica che sei arrabbiato
24 (rimorso)	25 (tristezza)	Il rimorso implica la tristezza in molti casi
1 (divertimento)	17 (gioia)	Se sei divertito molto probabilmente provi anche della gioia
23 (solievo)	17 (gioia)	Se sei sollevato molto probabilmente sarai felice di ciò
13 (entusiasmo)	17 (gioia)	L'entusiasmo implica la gioia

Table 1: Tabella delle emozioni e delle emozioni che inglobano

## 7 Bilanciamento

Dopo queste modifiche abbiamo notato che il dataset non era per nulla bilanciato, il che va anche bene perchè volevamo renderlo quanto più è fedele alla realtà, però per il nostro scopo era troppo sbilanciato, ad esempio l'emozione neutra compare più di 12000 volte, e invece l'altra emozione più predominante era ammirazione con più di 5000, quindi abbiamo deciso di dimezzare le istanze con l'emozione neutra. Inoltre le emozioni negative erano dimeno di quelle positive, come si poteva aspettare perchè anche nel dataset originale era così, quindi abbiamo deciso di aumentare leggermente le istahnze di quelle negative.

## 8 Differenza tra dataset iniziale e bilanciato

Sul dataset iniziale sono state effettuate varie modifiche sulle colonne,inizialmente il dataset conteneva altre informazioni come id del messaggio,autore del messaggio,l'id del link del messaggio ed ecc... .Tali informazioni ritenute non necessarie per il conseguimento dell'obiettivo finale,cioè la predizione dell'emozione sulla base dell'addestramento sul dataset.

Sono state ridefinite le colonne,eliminando quelle contenenti le info descritte precedentemente,lasciando solo le colonne relative al testo del messaggio e l'emozione associata,così anche da avere un dataset meglio organizzato,per l'addestramento del modello,ma anche per effettuare ulteriori operazioni future sui dati. Inoltre sono state accorpate varie emozioni come definita nell'immagine 1,dimezzate le istanze dell'emozione neutra ed aumentato leggermente le istanze delle emozioni negative